

COCO Pretrained YOLOv8n 대비 3-Class 검출 성능 향상 연구

학번: 20211435

프로젝트: CV_project#1

작성일: 2026-04-20

초록

본 연구는 VOC 기반 3-class(person, car, dog) 객체검출 과제에서 COCO pretrained yolov8n.pt를 기준선(B0)으로 두고, 하이퍼파라미터 및 데이터 구성 최적화를 통해 성능 향상을 달성하는 것을 목표로 한다. 핵심 전략은 (1) 변수 영향 ablation, (2) 증강 강도 재설계, (3) 전체 레이어 미세조정, (4) 배경(negative) 샘플 포함, (5) seed 반복 및 통계 검정이다. 최종 모델(last_squeeze 계열)은 5-seed 평균 기준 $mAP_{50-95}=0.6626$ 으로 B0(0.6245) 대비 $+0.0381$ 향상되었다. seed-level 검정(one-sided sign test, sign-flip permutation)은 모두 $p=0.03125$ 로 유의했으며, image-level paired-bootstrap에서는 $p=0.0612$ 로 엄격 기준에서 경계적 결과를 보였다. 본 보고서는 성능 향상 요인과 함께, 데이터 구성 차이가 결과 해석에 미치는 영향을 정량적으로 정리한다.

1. 서론

COCO pretrained 모델은 일반 객체 분포에서 강한 초기 성능을 보이지만, 소규모/도메인 편향 데이터셋에서는 과제 특이적 미세조정이 필요하다. 본 연구의 목적은 다음 두 가지다.

1. 3-class 도메인에서 COCO 기준선을 일관되게 상회하는 모델을 구축한다.
2. 향상이 통계적으로 유의한지 seed-level과 image-level 모두에서 검증한다.

2. 실험 설정


2.1 데이터셋 및 평가 프로토콜

- 타깃 클래스: person, car, dog
- 1차 지표: mAP50-95
- 보조 지표: mAP50, mAP75, 클래스별 AP, 4x4 confusion matrix(배경 포함)
- 비교 대상:
 - B0: COCO pretrained raw (yolov8n.pt)
 - Final: last_squeeze 최종 미세조정 모델
- 통계 검정:
 - seed-level: sign test, sign-flip permutation, bootstrap CI
 - image-level: paired-bootstrap

2.2 Baseline과 Final의 데이터 구성 차이

Baseline은 타깃 클래스가 포함된 양성 이미지 위주였고, Final은 배경(무라벨) 샘플을 학습에 명시적으로 포함했다.

구성	train_images	empty_label_images	effective_train
baseline_voc3	150	0	
final_last_squeeze	4086	1268	



dataset_comp_bar

이 차이는 FP 억제 성능 및 임계값 운영 특성에 직접 영향을 주므로, 최종 성능 해석 시 파라미터 효과와 데이터 분포 효과를 함께 고려해야 한다.

2.3 이미지 편향과 완화 전략

Baseline과 Final의 핵심 차이는 단순 샘플 수 증가가 아니라, 학습 데이터의 편향 구조를 바꾼 점이다.


1. Baseline 편향

- 배경 결핍: $bg_ratio = 0.0$ (empty-label 이미지 없음)
- 클래스 불균형: 인스턴스 비율 person 72.35% / car 22.48% / dog 5.17%
- 희소 클래스(특히 dog) 노출 부족: dog 포함 이미지 비율 12.67%


2. Final 편향 완화

- 배경 샘플 포함: unique 기준 $bg_ratio = 31.03\%$ 로 배경 prior를 학습에 반영
- dog 반복 샘플링 적용: repeat_seq 기준 dog 인스턴스 비율 21.53%, dog 포함 이미지 비율 31.48%까지 상승
- 결과적으로 배경 결핍과 dog 희소성이라는 baseline의 두 가지 이미지 편향을 동시에 완화

시나리오	images_total	bg_ratio	inst_person	inst_car	inst_dog
Baseline(voc3)	150	0.000	0.724	0.225	0.051
Final(unique)	4086	0.310	0.714	0.216	0.070
Final(repeat)	5349	0.237	0.617	0.167	0.216



dataset_bias_instance




dataset_bias_presence

3. 방법론

3.1 변수 영향 분석(Ablation)

초기 단계에서 epochs, imgsz, batch, lr0, freeze를 중심으로 단일 변수 변경 실험을 수행하여 민감도를 파악했다.



ablation_summary

3.2 최종 미세조정 설정

Final 설정은 다음과 같다.

- optimizer=SGD
- epochs=18, imgsz=640, batch=16


- lr0=0.00035, lrf=0.02, momentum=0.937, weight_decay=0.00045
- box=7.8, cls=0.45, dfl=1.35
- mosaic=0.05, close_mosaic=1, translate=0.05, scale=0.35
- hsv_s=0.6, hsv_v=0.3
- freeze=0, patience=20

설계 의도는 “강한 합성 증강 완화 + 전체 레이어 적응 + 안정적 학습률 스케줄”이다.

3.3 Baseline 대비 주요 하이퍼파라미터 변경

Baseline vs Final Hyperparameter Differences and Rationale

param	baseline	final	why_changed
optimizer	auto (runtime-selected)	SGD (fixed)	optimizer auto can override user lr/momentum, fixed optimizer improves stability
epochs	10	18	extended training budget after pipeline stabilization
lr0	0.001 (ignored by auto optimizer)	0.00035	lower initial LR for safer fine-tuning from strong checkpoint
lrf	0.01	0.02	slightly higher terminal LR ratio paired with low lr0
warmup_epochs	3.0	1.0	reduced warmup since starting from tuned checkpoint (not cold start)
weight_decay	0.0005	0.00045	slightly relaxed regularization to retain small-object details
freeze	5	0	unfreeze all layers for full domain adaptation on expanded training sets
mosaic	1.0	0.05	aggressive mosaic introduced distribution shift and FP trade-offs
close_mosaic	10	1	turn off mosaic much earlier in training
translate	0.1	0.05	weaken geometric perturbation to reduce boundary artifacts
scale	0.5	0.35	reduce extreme scale jitter
hsv_s	0.7	0.6	moderate color augmentation strength
hsv_v	0.4	0.3	lower brightness perturbation
box	7.5	7.8	slightly upweight localization term
cls	0.5	0.45	slightly downweight classification loss
dfl	1.5	1.35	rebalanced regression distribution loss with above weights
patience	100	20	avoid very long overfitting tail and speed repeat experiments
imgsz	640	640	kept fixed for fair throughput/latency
batch	16	16	kept fixed due to memory/stability trade-off



핵심 변경의 역할은 다음과 같다.

1. optimizer auto -> SGD: 학습 동작 고정, 재현성 개선
2. freeze 5 -> 0: 전체 네트워크 도메인 적응
3. mosaic 1.0 -> 0.05, close_mosaic 10 -> 1: 과도한 분포 왜곡 억제

- 4. lr 0.001 -> 0.00035: pretrained 가중치의 급격한 붕괴 방지
- 5. box/cls/df1 재균형: 위치 정밀도와 오탐 trade-off 조정



4. 실험 결과

4.1 기준선 대비 성능

B0(COCO raw)는 mAP50=0.8250, mAP75=0.6813, mAP50-95=0.6245였다.

Final은 5-seed 평균 기준 mAP50=0.8750, mAP75=0.7187, mAP50-95=0.6626을 기록했다.

지표	B0	Final(5-seed mean)	Delta
mAP50	0.8250	0.8750	+0.0499
mAP75	0.6813	0.7187	+0.0374
mAP50-95	0.6245	0.6626	+0.0381



4.2 통계적 유의성

mAP50-95 기준:


- seed-level sign test(one-sided): $p=0.03125$
- seed-level sign-flip permutation(one-sided): $p=0.03125$
- seed bootstrap 95% CI: $[+0.0342, +0.0418]$
- image-level paired-bootstrap mean delta: $+0.0083$
- image-level paired-bootstrap 95% CI: $[-0.0022, +0.0202]$
- image-level paired-bootstrap(one-sided): $p=0.0612$

mAP50 보조 검정:

- seed-level mean delta: $+0.0499$
- image-level paired-bootstrap(one-sided): $p=0.0294$
- image-level 95% CI: $[-0.0004, +0.0226]$ (경계적)

해석: - seed-level에서는 일관된 개선이 확인된다. - image-level 엄격 기준에서는 표본 변동성 때문에 유의성이 경계적이다.

4.3 Confusion Matrix 분석(4x4, 배경 포함)



관찰된 주요 변화:

항목	Baseline	Final	Delta
person -> person (TP)	160	163	+3
car -> car (TP)	56	58	+2
dog -> dog (TP)	13	15	+2
bg/other -> person (FP to person)	106	88	-18
bg/other -> car (FP to car)	25	43	+18
bg/other -> dog (FP to dog)	2	6	+4

즉, person FP는 감소했지만 car/dog 방향 FP가 증가하는 trade-off가 존재한다.

4.4 모델별 통계 유의성 충족 여부

판정 기준은 기본적으로 $\alpha=0.05$ 이며, image-level 검정에서는 95% CI가 0을 포함하지 않을 것을 엄격 기준으로 추가했다.

모델/실험군	비교 기준	지표	검정 결과	판정
n_gentle_1 (COCO surpass 1차 후보)	COCO F1	F1 delta	mean -0.0299, t-test(one-sided) $p=0.9994$, Wilcoxon $p=1.0$	유의성 미충족
mstar_staged (protocol)	B0(COCO raw)	mAP50-95 delta	bootstrap mean -0.0020, 95% CI [-0.0076, +0.0039], one-sided $p=0.7556$	유의성 미충족
mstar_staged (protocol)	B1(기본 FT)	mAP50-95 delta	bootstrap mean +0.0439, 95% CI [+0.0383, +0.0498], one-sided $p=0.0$	유의성 충족 (B1 대비)
last_squeeze 최종	B0(COCO raw)	mAP50-95 delta (seed-level)	$p=0.03125$, bootstrap CI [+0.0342, +0.0418]	유의성 충족 (seed-level)
last_squeeze 최종	B0(COCO raw)	mAP50-95 delta (image-level paired-bootstrap)	mean +0.0083, 95% CI [-0.0022, +0.0202], one-sided $p=0.0612$	엄격 기준 미충족
lg_02 운영 2차 튜닝	lg_02 운영 baseline	F1/FP 운영 개선	F1 bootstrap 95% CI [+0.0085, +0.0396], $p\sim0.0006$	유의성 충족 (운영 파라미터 수준)

유의성 미충족 사례는 실제로 존재하며, 특히 다음 3가지는 명확히 “미충족”이다.

1. n_gentle_1의 COCO 직접 추월 주장(F1 기준)

- 2. mstar_staged의 B0 직접 우위 주장(mAP50-95 기준)
- 3. last_squeeze의 image-level 엄격 기준(mAP50-95 paired-bootstrap)


또한 초기 탐색군(opt_*, aug_*, lg_* 일부)은 단일 run 위주로 수행되어, p-value 기반 유의성 판정 자체를 적용하기 어렵다(반복/재표본 검정 미실시).

5. 시행착오 로그(최종 결과 외 전 과정)

5.1 단계별 시행착오 타임라인

아래 표는 “무엇을 시도했고, 왜 실패/부분성공이었는지”를 정량값과 함께 요약한 것이다.

단계	실험군	대표 지표	결과	판정	핵심 해석
P1	baseline 구축	mAP50-95	0.4219	기준선	양성 위주 소규모 데이터 기준선
P2	1차 ablation	mAP50-95	0.4655	성공	freeze/epochs 조정으로 초기 개선
P3	초기 최적화	mAP50-95	0.4708	성공	lr/batch/freeze 탐색 이득은 제한적
P4	강한 증강 탐색	mAP50-95	0.4699	실패	과증강으로 분포 왜곡, 개선 정체
P5	데이터 확장+증강	mAP50-95	0.4822	부분성공	평균은 개선, 변동성은 큼
P6	2-stage 프로토콜	val mAP50-95	0.5783	부분성공	val 고점, test 일반화 불확실
P7	프로토콜 교정+last_squeeze	mAP50-95	0.6626	성공	공정 비교에서 B0 대비 +0.0381



trial_timeline

5.2 대표 실패 케이스와 수정 조치

1. 이전 best.pt 연속 학습 이슈

초기 일부 구간은 “같은 기준선에서 독립 비교”가 흐려질 수 있는 학습 경로가 섞여, 변수 영향 분리가 어려웠다. 이후 모든 비교를 yolov8n.pt 기준 독립 학습으로 재정렬했다.

2. 과한 증강 설정

mosaic/mixup 강도를 높인 실험은 mAP50-95 개선이 미미하거나 역효과를 보였다(P4). 최종에서는 증강 강도를 낮추고(mosaic=0.05) 조기 종료(close_mosaic=1)로 전환했다.

3. val 고점 과신

P7에서 val 지표가 높았지만, 후속 seed/test 검증(P8)에서 B0 대비 음수 델타가 관측되었다. 이로 인해 단일 split 고점을 채택하지 않고 seed 반복 검정을 필수화했다.

4. 운영 파라미터 단독 튜닝 한계

임계값/운영점 조정만으로는 COCO 추월이 재현되지 않았다(P6). 이후 학습 레벨(데이터+하이퍼파라미터+프로토콜) 개선으로 방향을 전환했다.

5.3 시행착오가 최종 설계에 반영된 방식

최종 설계는 단일 아이디어가 아니라, 실패에서 확인된 제약을 차례로 반영한 결과다.

1. 비교 공정성: 동일 기준선과 독립 학습 프로토콜 고정
2. 일반화 우선: 단일 val 고점보다 5-seed 반복 결과를 채택
3. 데이터 분포 보정: negative 샘플 포함으로 배경 오탐 구조 학습
4. 증강 절제: 강한 합성 증강을 약화하고 후반 수렴 안정화

6. 논의

6.1 왜 성능이 상승했는가

성능 상승은 단일 요인보다는 다음의 복합 효과로 보는 것이 타당하다.

1. 학습 안정화: 낮은 lr_0 , 짧은 warmup, SGD 고정
2. 도메인 적응 강화: $freeze=0$ 전체 미세조정
3. 데이터 분포 보완: 배경 negative 31% 포함으로 운영 환경 유사성 개선
4. 증강 현실화: 과도한 mosaic/기하 변환 완화

6.2 한계와 향후 과제

image-level paired-bootstrap에서 $p=0.0612$ 로 0.05를 소폭 상회했다. 엄격 기준까지 통과하려면 아래가 필요하다.

1. 테스트 표본 확대 또는 OOF 기반 재평가
2. seed 수 추가 확장(예: 10 seeds 이상)
3. FP가 증가한 car/dog 채널 중심 운영 threshold 재최적화

7. 결론

본 연구는 COCO pretrained YOLOv8n 대비 3-class 과제에서 최종 모델이 평균 성능을 꾸준히 상회함을 확인했다. seed-level 통계 검정에서는 유의한 개선이 관찰되었고, image-level 검정에서는 경계적 결과가 나타났다. 따라서 현재 결론은 “실무적으로 개선 신호가 분명하나, 엄격한 통계 기준 완전 충족을 위해 추가 표본 기반 검증이 필요”로 요약된다.